

UOS - Capstone

Week 5 - Generating and Evaluating Synthetic Data

박상훈 ¹

2026학년도 2학기

¹Gwanak Lab Co., Ltd., Korea
E. sanghun.park@gwanaklab.co.kr

지난 시간 리뷰

생성이란 무엇인가

VAE 학습과 생성

Latent Space 관찰

β -VAE

VAE에서 더 깊고 갈 것

좋은 합성데이터란 무엇인가

지난 시간 리뷰

- Tabular 데이터를 전처리하고 **AutoEncoder**로 압축 / 복원했습니다.
- 학습된 Latent를 **PCA**와 **KDE**로 시각화했습니다.
- 두 latent의 **내분점**을 Decoder에 넣어 “새로운 데이터”를 만들어 봤습니다.
- 마지막으로 AutoEncoder 코드를 고쳐 **VAE**를 직접 구현했습니다.

오늘은 VAE를 왜 그렇게 만들었는지부터 다시 따라가 봅시다.
그 다음 학습시키고, 생성하고, 잘 만들어졌는지 채점합니다.

1. 생성이란 무엇인가 — 무엇이 있어야 데이터를 만들 수 있는지 따져봅니다.
2. VAE 학습과 생성 — 학습시키고 실제로 데이터를 만들어 봅니다.
3. Latent Space 관찰 — 우리가 의도한 대로 되었는지 그림으로 확인합니다.
4. β -VAE — β 를 바꿔가며 KL 항의 역할을 눈으로 봅니다.
5. 좋은 합성데이터란 무엇인가 — 평가 지표를 조사하고, 발표하고, 구현해서 오늘 만든 데이터를 실제로 채점합니다.

오늘의 목표: “잘 만들어진 것 같다”를 숫자로 바꾸는 것

생성이란 무엇인가


문제 1. 무엇이 더 있어야 “생성”이 되는가

문제 1

학습이 끝난 AutoEncoder가 있습니다. 이것으로 **한 번도 본 적 없는** 데이터를 만들려면 무엇이 필요할까요?



생성



- 생성할 때는 Encoder가 필요 없습니다. 그렇다면 무엇이 빠져 있나요?
- 즉 “데이터를 생성한다”는 문제는 결국 어떤 문제로 바뀌나요?

문제 2. 새로운 z 는 어떻게 만들 수 있을까

문제 2

Decoder에 넣을 새로운 z 를 만드는 방법을 **떠오르는 대로** 적어 봅시다.

(A) 규칙으로 만들기 — 이미 가지고 있는 latent들을 가지고 계산해서 만드는 방법.

- 지난 시간에 한 **내분점** $z = \lambda z_1 + (1 - \lambda)z_2$
- 기존 latent에 작은 노이즈 더하기, 여러 latent의 평균, ...

(B) 분포에서 뽑기 — latent들이 따르는 분포를 하나 정해 놓고 거기서 **샘플링**하는 방법.

- (A)로 만든 z 는 **기존 데이터에 매여 있습니다**. 이것이 왜 한계인가요?
- (A)로 서로 다른 데이터를 **100만 개** 만들 수 있나요?
- (B)로 가려면 무엇을 먼저 정해야 하나요?

문제 3. 그렇다면 어느 분포에서 뽑을 것인가

문제 3

학습이 끝난 **AutoEncoder**의 latent에 분포를 하나 씌워서 뽑아 봅시다. 무엇을 씌우는 것이 좋을까요?

- 아래 네 가지로 각각 z 를 뽑아 Decoder에 넣고, 나온 데이터를 비교하세요.
 - 표준정규분포 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 에서 그냥 뽑기
 - latent의 평균과 공분산으로 **정규분포를 하나** 적합시켜 뽑기
 - **GMM**을 적합시켜 뽑기 (성분 개수도 바꿔가며)
- 지난 시간에 그린 AE의 latent 그림은 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 처럼 생겼었나요? 아니라면 첫 번째 방법은 어떤 결과를 낼까요?

문제 3 (계속). 이 방법들의 공통된 한계

문제 3 (계속)

GMM이나 KDE로 잘 맞추면 되는 것 아닐까요? 다음을 확인해 봅시다.

1. latent 차원 d 를 2, 8, 32, 128로 바꿔가며 GMM과 KDE를 적합시켜 보세요. 차원이 커질 때 무엇이 어려워지나요? 데이터는 몇 개나 필요해 보이나요?
2. latent에 **빈 공간**(아무 데이터도 없는 영역)이 있다면, 어떤 분포를 씌우더라도 그 공간을 피할 수 있나요?
3. 이 방법들은 모두 **학습이 끝난 뒤에** 분포를 맞춰 끼우는 방식입니다. 여기서 오는 본질적인 문제는 무엇일까요?

latent의 모양은 우리가 고른 것이 아니라, AutoEncoder가 복원만 잘 하려다 **우연히** 만들어진 모양입니다.

문제 4. 그렇다면 VAE는 무슨 생각을 한 것일까

문제 4

분포를 나중에 맞추는 것이 어렵다면, **순서를 바꾸면** 어떨까요?

- 학습이 끝난 뒤에 latent의 분포를 추정하는 대신, **처음부터 우리가 원하는 분포가 되도록** 학습시킬 수는 없을까요?
- 그러려면 학습 과정에 무엇을 추가해야 할까요?
 - 학습할 때부터 z 를 **하나의 점**이 아니라 **분포에서 뽑아** 쓰게 하려면?
 - 그 분포가 우리가 원하는 모양($\mathcal{N}(\mathbf{0}, \mathbf{I})$)에서 멀어지면 **손해를 보게** 하려면?
- 지난 시간 여러분이 작성한 VAE 코드에서 이 두 가지가 각각 **어느** 줄인지 찾아보세요.

분포를 나중에 맞추는 대신, 분포를 미리 정해 놓고 거기에 맞춰 학습한다.

결정 1 — 샘플링하며 학습

- Encoder가 $\mathbf{z}$ 하나가 아니라 μ, σ 를 출력
- 학습 중에도 $\mathbf{z}$ 를 뽑아서 Decoder에 넣음
- $\Rightarrow$ Decoder가 점이 아니라 영역을 보게 됨

결정 2 — 모양에 벌점

- $q(\mathbf{z} | \mathbf{x})$ 가 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 에서 멀어지면 KL 항이 커짐
- $\Rightarrow$ latent가 우리가 아는 모양으로 끌려옴

$$\mathcal{L}_{\text{VAE}} = \underbrace{\mathcal{L}_{\text{recon}}}_{\text{복원}} + \underbrace{\mathcal{L}_{\text{KL}}}_{\text{모양 맞추기}} \quad (1)$$

두 결정이 모두 있어야 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 에서 뽑아 Decoder에 넣는 것이 정당해집니다.

VAE 학습과 생성

문제 5

지난 시간에 만든 VAE를 실제로 학습시켜 봅시다.

- 이미지와 Tabular 데이터 각각에 대해 학습을 진행하세요.
- 학습 로그에 **전체 loss 하나만** 찍지 말고, **복원 항**과 **KL 항**을 **따로** 기록하세요.
- 두 항은 학습이 진행되면서 각각 어떻게 움직이나요? 같은 방향으로 줄어드나요?

두 항을 따로 기록해 두어야 뒤의 문제 11, 12를 풀 수 있습니다.

문제 6. 세 종류의 데이터 만들기

문제 6

앞으로 계속 비교할 **세 개의 데이터셋**을 만들어 둡시다.

- (a) 원본 — 학습에 사용한 실제 데이터
 - (b) 복원 — 원본을 Encoder에 넣어 얻은 $\mathbf{z}$ 를 다시 Decoder에 통과시킨 것
 - (c) 생성 — $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 에서 **직접 뽑아** Decoder에 넣은 것
- (b)와 (c)는 무엇이 다른가요? 어느 쪽이 더 원본과 비슷할 것이라고 예상하나요?
 - (c)를 문제 3의 네 가지 방법으로 만든 것과도 비교해 보세요. 차이가 있나요?
 - (c)는 원본과 **행 개수를 같게** 만들어 두세요. 뒤에서 평가할 때 필요합니다.

문제 7. 생성 결과를 원래 형태로 되돌리기

문제 7

Decoder의 출력은 아직 “데이터”가 아닙니다. 원래의 표 형태로 되돌려 봅시다.

- **연속형**: 전처리에 사용한 변환(Standard / Quantile)의 **역변환**을 적용하세요.
- **범주형**: Decoder는 각 범주의 확률 (0.3, 0.4, 0.3) 같은 값을 출력합니다. 이것을 하나의 범주로 정하는 방법을 **두 가지** 써 보세요.
 - 가장 큰 값을 고르기 ($\arg \max$)
 - 그 확률대로 무작위로 뽑기 (multinomial sampling)
- 두 방법으로 만든 데이터의 **범주별 빈도**를 원본과 비교하세요. 무엇이 달라지나요? 특히 **드물게 나오는 범주**는 어떻게 되나요?

문제 8

문제 6에서 만든 세 데이터가 서로 얼마나 다른지 확인해 봅시다.

- **열 하나씩**: 세 데이터의 히스토그램을 한 그림에 겹쳐 그리세요. (연속형 / 범주형 모두)
- **열 두 개씩**: 열 사이의 **상관행렬**을 각각 구하고, 원본과의 차이를 heatmap으로 그리세요.
- 한 열씩 볼 때는 괜찮은데 두 열을 같이 보면 깨지는 경우가 있나요?

여기까지가 “눈으로 보는” 평가입니다. 오늘 후반부에 이것을 **숫자**로 바꿉니다.

Latent Space 관찰

문제 9. Latent Space 시각화 — 규격

문제 9

아래 규격에 맞춰 latent space를 그려 봅시다. **행이 3개**인 것이 핵심입니다.

	β 작게	$\beta = 1$	β 크게
$p(\mathbf{z})$			
$q(\mathbf{z})$			
Labels			

1행 $p(\mathbf{z})$: prior $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 에서 뽑은 $\mathbf{z}$ 의 KDE

2행 $q(\mathbf{z})$: 전체 학습 데이터를 Encoder에 통과시켜 얻은 $\mathbf{z}$ (또는 μ)의 KDE

3행 Labels: 2행과 같은 $\mathbf{z}$ 를 라벨로 색칠한 산점도

- 열은 나중에 β 값으로 채웁니다 (문제 11). 지금은 1열만 그려도 됩니다.

문제 9 (계속). 반드시 지킬 것

- PCA는 한 번만 fit합니다. $q(\mathbf{z})$ 로 학습시킨 PCA를 prior 샘플에도 그대로 적용하세요. 행마다 따로 PCA를 돌리면 두 그림을 비교할 수 없습니다.
- 세 행의 축 범위(xlim, ylim)를 똑같이 고정하세요.
- KDE는 같은 colormap과 같은 등고선 개수를 쓰세요.

같은 자 위에 올려놓아야 비교가 됩니다.
1행과 2행이 겹치는지를 보는 것이 이 그림의 목적입니다.

(라벨이 없는 Tabular 데이터라면, 하나의 범주형 열이나 target 변수를 라벨 대신 사용하세요.)

문제 9 (계속). 코드 뼈대

```
# 1) 공통 PCA 축 :  $q(z)$ 로 fit하고, prior 샘플에도 같은 변환을 적용
z_q = encode_all(X_train) # (n, d) :  $\mu$  사용
pca = PCA(n_components=2).fit(z_q)
Q = pca.transform(z_q)
P = pca.transform(np.random.randn(len(z_q), d)) # prior 샘플

# 2) 3행 x (beta 개수) 격자
fig, ax = plt.subplots(3, n_beta, figsize=(3*n_beta, 8.5), squeeze=False)
sns.kdeplot(x=P[:, 0], y=P[:, 1], fill=True, cmap="Blues", levels=15, ax=ax[0, j])
sns.kdeplot(x=Q[:, 0], y=Q[:, 1], fill=True, cmap="Blues", levels=15, ax=ax[1, j])
ax[2, j].scatter(Q[:, 0], Q[:, 1], c=labels, cmap="Set2", s=6, alpha=0.7)

# 3) 세 행의 축 범위 통일 <- 빠뜨리기 쉬움
for i in range(3):
    ax[i, j].set_xlim(...); ax[i, j].set_ylim(...)
```

문제 10

우리는 문제 4에서 latent가 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ 가 되도록 학습시켰습니다. 정말 그렇게 되었는지 1행과 2행을 나란히 놓고 확인해 봅시다.

1. 두 분포는 겹치나요? 겹치지 않는 영역이 있다면 어디인가요?
2. 1행에는 있는데 2행에는 없는 영역에서 $\mathbf{z}$ 를 뽑아 Decoder에 넣으면 어떤 데이터가 나올까요? 직접 해보세요.
3. 문제 6의 (b) 복원과 (c) 생성의 품질 차이를 이 그림으로 설명할 수 있나요?
4. 3행의 라벨은 잘 나뉘어 있나요? 나뉘어 있다면 그것은 무엇을 뜻하나요?

문제 3에서 본 AutoEncoder의 latent와 비교하면 무엇이 나아졌고, 무엇이 아직 남아 있나요?

β -VAE

문제 11. β 를 바꿔가며 학습하기

문제 11

VAE의 loss에서 KL 항 앞에 상수 β 를 붙이고, 값을 고정해 여러 번 학습해 봅시다.

$$\mathcal{L}_{\beta\text{-VAE}} = \mathcal{L}_{\text{recon}} + \beta \mathcal{L}_{\text{KL}} \quad (2)$$

- $\beta \in \{0, 0.1, 1, 10\}$ 정도로 각각 학습하세요. ($\beta = 0$ 이면 이 모델은 사실상 무엇이 되나요?)
- 각 β 에 대해 문제 9의 **3행 그림**을 그리고, **열로 나란히** 붙이세요.
- 각 β 에 대해 문제 6의 (c) 생성 데이터도 만들어 두세요.

문제 12. β 가 만드는 trade-off

문제 12

β 를 키우면 무엇이 좋아지고 무엇이 나빠지는지 **숫자로** 확인해 봅시다.

- 각 β 에 대해 학습이 끝난 뒤의 **복원 오차**와 **KL 값**을 표로 정리하세요.
- 가로축을 KL, 세로축을 복원 오차로 두고 점을 찍어 보세요. 어떤 모양이 나오나요?
- β 가 커질 때 문제 9의 **1행과 2행**은 서로 가까워지나요, 멀어지나요?
- 그렇다면 **3행(라벨)**은 어떻게 되나요? 여기서 무엇을 잃고 있나요?

“ β 를 얼마로 두어야 하는가”에 하나의 정답이 있는지 생각해 보세요.

문제 13. 쓰이지 않는 차원 찾기

문제 13

β 를 크게 하면 latent의 일부 차원이 **아무 일도 하지 않게** 됩니다. 확인해 봅시다.

- KL을 전체 합이 아니라 **latent 차원별로** 계산해 막대그래프로 그리세요.
- 값이 거의 0인 차원이 있나요? 그 차원의 μ 와 σ 는 어떤 값인가요?
- β 를 키울수록 그런 차원의 개수는 어떻게 변하나요?
- 그 차원의 z 값만 바뀌서 Decoder에 넣으면 출력이 변하나요?

이 현상의 이름을 찾아보세요. 그리고 **왜** 일어나는지 설명해 보세요.

VAE에서 더 짚고 갈 것

좋은 합성데이터란 무엇인가

문제 14. 무엇을 보고 “좋다”고 할 것인가

문제 16

지금까지 “비슷해 보인다”로 판단해 왔습니다. 그런데 합성데이터가 좋다는 것은 **정확히 무엇이 좋다는** 뜻일까요?

- 합성데이터를 평가할 때 볼 수 있는 **측면(관점)**에는 어떤 것들이 있을지 **5분간** 각자 찾아보세요.
- 힌트가 되는 질문들:
 - 원본과 똑같이 생겼으면 그것으로 충분한가?
 - 이 데이터를 받아서 **무엇을 하려는** 사람인가?
 - 원본을 그대로 복사해 제출하면 몇 점을 받아야 하는가?

- 최근 서베이 논문은 합성 정형데이터의 평가를 다음 다섯 축으로 정리합니다.

Utility	이 데이터를 실제로 썼을 때 쓸모가 있는가
Alignment	도메인 지식 에 부합하는가 (예: 나이 ≥ 0 , 퇴사일 $\geq$ 입사일)
Fidelity	원본의 분포와 통계적으로 얼마나 닮았는가
Privacy	원본 개인의 정보를 흘리지 않는가
Diversity	샘플이 얼마나 다양한가

M. C. Stoian, E. Giunchiglia, T. Lukasiewicz, "A Survey on Deep Learning Approaches for Tabular Data Generation: Utility, Alignment, Fidelity, Privacy, Diversity, and Beyond," TMLR, 2026.

이 논문은 각 축에 맞는 **평가 방법과 축들 사이의 관계**까지 정리해 두었습니다. 문제 17과 20을 풀기 전에 해당 절을 찾아 읽으세요.

문제 15. 축마다 지표 두 개씩 찾기

문제 17

다섯 축 각각에 대해 구체적인 평가 지표를 두 개씩 찾아 아래 표를 채우세요.

축	지표 1	지표 2	무엇을 입력으로 받는가
Utility			
Alignment			
Fidelity			
Privacy			
Diversity			

마지막 열이 중요합니다. 원본만 필요한가, 합성데이터만 필요한가, 아니면 학습에 쓰지 않은 홀드아웃 데이터까지 필요한가?

문제 16. 조사하고 서로에게 설명하기

문제 18

한 사람이 한 축을 맡아, 자신이 찾은 지표를 나머지에게 **5분간** 설명해 주세요.

설명에 반드시 포함할 것

1. 이 지표는 무엇을 재는가 — 한 문장으로
2. 어떻게 계산하는가 — 수식 또는 계산 절차
3. 입력은 무엇인가 — 원본 / 합성 / 홀드아웃 중 무엇이 필요한가
4. 값의 범위와 좋은 방향 — 높을수록 좋은가, 낮을수록 좋은가, 아니면 특정 값에 가까울수록 좋은가
5. 이 지표의 한계 — 이 지표만 보면 속을 수 있는 경우는?

5번이 가장 중요합니다. **속이기 쉬운 지표**를 찾아내는 것이 오늘의 핵심입니다.

문제 17. 실제로 채점해 보기

문제 19 — 오늘의 목표

조사한 지표를 직접 구현하거나 구현된 코드를 찾아서, 오늘 만든 데이터를 실제로 평가하세요.

- 간단한 지표는 직접 구현하세요. 남의 코드를 쓰기 전에 무엇을 계산하는지 알고 있어야 합니다.
- 복잡한 지표는 공개된 구현을 찾아 쓰되, 입력 형식과 전처리 요구사항을 반드시 확인하세요.
- 평가 대상: 문제 11에서 β 별로 만든 생성 데이터 전부.

막히면: 합성데이터 평가용 오픈소스 툴킷을 먼저 검색해 보세요. 다만 설치해서 돌리는 것이 목표가 아니라 값을 해석하는 것이 목표입니다.

논문들 제목이라도 알아 두기를 추천합니다!

- D. P. Kingma and M. Welling, "Auto-Encoding Variational Bayes," ICLR, 2014.
- I. Higgins et al., " β -VAE: Learning Basic Visual Concepts with a Constrained Variational Framework," ICLR, 2017.
- J. Tomczak and M. Welling, "VAE with a VampPrior," AISTATS, 2018.
- L. Xu et al., "Modeling Tabular Data using Conditional GAN," NeurIPS, 2019.
- M. C. Stoian, E. Giunchiglia, T. Lukasiewicz, "A Survey on Deep Learning Approaches for Tabular Data Generation: Utility, Alignment, Fidelity, Privacy, Diversity, and Beyond," *Transactions on Machine Learning Research*, 2026.
<https://openreview.net/forum?id=RoShSRQQ67> (arXiv: 2503.05954)